

SIDANG TUGAS AKHIR

Muhammad Hashfi Hadyan

Back-end developer (AI integration & Analytics)

PENGEMBANGAN BACKEND INTEGRASI AI DAN ANALITIK UNTUK WEBSITE CHATBOT KOLABORATIF BERBASIS FASTAPI

LATAR BELAKANG

Chatbot edukasi sudah banyak, tapi...

Kebanyakan bersifat satu arah

- Mahasiswa tanya → chatbot jawab
- Tidak ada interaksi antar mahasiswa

Masalah Halusinasi pada LLM

- Jawaban terdengar meyakinkan tapi salah
- Berbahaya untuk konteks akademik

Sulit monitor keterlibatan mahasiswa

- Dosen tidak tahu siapa yang aktif/pasif
- Tidak ada data untuk intervensi dini

LATAR BELAKANG

Gap yang ditemukan

Yang ada	Yang belum ada
Chatbot QA	Chatbot Kolaboratif
LLM Standalone	RAG + Guardrails
Analytics umum	SSR-specific monitoring
Monolitik	Microservicees

RUMUSAN MASALAH

Akurasi & Keamanan

Bagaimana merancang RAG pipeline dengan guardrails untuk mengurangi halusinasi pada LLM?

Desain Backend

Bagaimana merancang arsitektur backend berbasis FastAPI untuk mendukung chatbot kolaboratif?

Logging & Analisis

Bagaimana merancang sistem logging terstruktur untuk mendukung Educational Process Mining?

TUJUAN PENELITIAN

Sistem RAG Terproteksi

Mengimplementasikan sistem RAG yang dilengkapi dengan modul Guardrails berlapis untuk memitigasi halusinasi model dan menyensor informasi sensitif sebelum diproses oleh LLM

Infrastruktur Data

Menyediakan API pencatatan log transaksi yang menyimpan data interaksi dalam format dokumen terstruktur (MongoDB), yang siap diekspor untuk analisis Process Mining.

Arsitektur Asinkron

Menghasilkan arsitektur backend microservices berbasis FastAPI yang menerapkan mekanisme Asynchronous I/O dan Background Tasks untuk menangani beban komputasi AI dengan latensi rendah.

TUJUAN PENELITIAN

Yang akan dibangun

Backend API dengan
FastAPI (async, scalable)

RAG pipeline dengan
guardrails berlapis

Logic Listener untuk
deteksi SSR & intervensi

Event logging standar XES
untuk EPM

BATASAN MASALAH

Backend (API, Logic,
Database)

OpenAI-Compatible API
(Gemini, GPT, Claude, dll)

Isolasi per mata kuliah

PaddleOCR

Dokumen Simulasi untuk
Testing


Tidak mengerjakan
Frontend & Data pribadi
minimal NIM, email

TINJAUAN PUSTAKA

Konsep	Referensi
RAG	Lewis et al. (2020)
Guardrails	Raihan (2026)
SSR	Zheng et al. (2023)
EPM	Bogarin et al. (20177)
FastAPI	Bednarz & Milosz (2025)
Gini Threshold	Strauß & Rummel (2021)


METODOLOGI

Iteratif – Inkremental (5 Iterasi)




METODOLOGI

Arsitektur Backend



METODOLOGI

RAG Pipeline



METODOLOGI

Desain Guardrails

Input Guardrails

- Regex Detection (prompt injection patterns)
- BERT Classifier (score > 0.8 = blocked)
- Toxicity Check
- PII Detection (NIM, email, phone)

Output Guardrails

- Grounding Verification (klaim harus ada di konteks)
- Direct Answer Block (Socratic approach)
- Pedagogical Alignment Check

METODOLOGI

Desain Logic Listener


Deteksi SSR:

1. Silence Detection ($\Delta t > 5$ menit $\rightarrow$ intervene)
2. Dominance Detection (Gini $> 0.6 \rightarrow$ intervene)
 - Threshold: Strauß & Rummel (2021)
 - Normalized: $\text{Gini} \times \sqrt{N_{\text{users}}}$
3. SRL Phase Classification
 - Forethought / Performance / Reflection

Output: NLG Intervention Prompt

METODOLOGI

Desain Event Logging & Analitik



METODOLOGI

Rencana Skenario Pengujian

Aspek	Verifikasi
API & Routing	Endpoint Test
Load Testing	Performance Test
RAG & Grounding	Accuracy Check
Guardrails	Security Test
Logging	XES Compliance
Analytics	Dashboard Test

IMPLEMENTASI

Komponen utama

Backend API

FastAPI, async endpoint,
routing, validation

RAG Pipeline

document chunking, embedding,
vector search, generation

Guardrails

prompt injection detection, PII
masking, grounding verification

Logic Listener

engagement metrics, SRL
phase, silence/dominance
detection, intervention trigger

IMPLEMENTASI


RAG Pipeline dan Guardrails Berlapis

RAG Pipeline:

- Dokumen diproses menjadi chunk
- Chunk diubah menjadi embedding
- Embedding disimpan di Qdrant
- Query pengguna dicocokkan dengan dokumen relevan
- Konteks dikirim ke LLM untuk menghasilkan jawaban

Guardrails:

- Deteksi prompt injection
- Masking PII: NIM, email, nomor telepon
- Grounding verification
- Validasi output agar tetap sesuai konteks pembelajaran



IMPLEMENTASI

Logic Listener untuk Analitik Diskusi

Fungsi Logic Listener:

- Menganalisis dinamika diskusi kelompok
- Mendeteksi silence dan dominance
- Mengklasifikasikan engagement mahasiswa
- Mengklasifikasikan fase SRL:
 - Forethought
 - Performance
 - Reflection
- Memicu intervensi otomatis

Chat History



Logic Listener



Analisis Diskusi

- Silence Detection
- Dominance Detection
- Engagement Classification
- SRL Phase Classification



NLG Intervention Prompt

IMPLEMENTASI

Pengujian Fungsional Backend

Ringkasan Pengujian

- Total test cases: 2.173
- Unit tests: 1.972
- Integration tests: 141
- Code coverage: 97,30%

Komponen yang diuji

- API endpoint dan routing
- Auth dan request validation
- RAG pipeline
- Injection detector
- PII detector
- Grounding verifier
- Redis cache
- Logging service

IMPLEMENTASI

Evaluasi RAG untuk Kualitas Jawaban dan Grounding

Hasil Evaluasi RAG:

- Keyword coverage meningkat:
84,0% → 94,0%
- MRR@5 = 0,88
- Evaluasi dilakukan pada 20 kueri akademik
- Cache semantik mempercepat query berulang

Keyword Coverage

Tanpa RAG



Dengan RAG



Makna hasil:

- Jawaban lebih terikat pada dokumen sumber
- Retrieval mampu mengambil konteks relevan
- Risiko halusinasi dapat ditekan

IMPLEMENTASI

Pengujian End-to-End dan Event Logging untuk EPM

Hasil End-to-End:

- 21 skenario end-to-end berhasil dijalankan
- Pengujian menggunakan data aktual
- Alur chatbot, RAG, guardrails, dan logging berjalan sesuai rancangan

Hasil Logging:

- 2.270 events
- 88 cases
- Dipetakan ke format kompatibel XES
- Mendukung Educational Process Mining



IMPLEMENTASI

Pengujian End-to-End dan Event Logging untuk EPM

Hasil End-to-End:

- 21 skenario end-to-end berhasil dijalankan
- Pengujian menggunakan data aktual
- Alur chatbot, RAG, guardrails, dan logging berjalan sesuai rancangan

Hasil Logging:

- 2.270 events
- 88 cases
- Dipetakan ke format kompatibel XES
- Mendukung Educational Process Mining



IMPLEMENTASI

Evaluasi Performa Backend AI Engine

Hasil Performa:

- Endpoint analitik lokal: 2–4 ms
- Throughput tertinggi: 672 RPS
- Pengujian pada 5 klien paralel
- Cache mempercepat RAG:
2.236 ms → 286 ms
- Speedup cache: $\pm 7,8\times$

RAG Query Latency

Cold Query	2.236 ms
Cached Query	286 ms

PENUTUP

Analisis Hasil, Keterbatasan, dan Rencana Lanjutan

Analisis:

- RAG meningkatkan keterikatan jawaban terhadap dokumen
- Guardrails membantu menjaga keamanan input dan output
- Async processing menjaga latensi endpoint lokal tetap rendah
- Logging sudah mendukung kebutuhan analitik EPM

Keterbatasan:

- Pengujian 50+ user belum dilakukan
- Evaluasi pedagogis belum diuji di kelas nyata
- Performa LLM masih bergantung pada provider/API
- Dataset evaluasi RAG masih terbatas

Rencana Lanjutan:

- Deployment ke staging/server
- Integrasi penuh dengan frontend
- Uji coba bersama dosen dan mahasiswa
- Pengujian konkuren skala lebih besar
- Penyempurnaan dashboard analytics