

MINGGU 2 ? DATA PREPROCESSING & K-MEANS CLUSTERING

Prasyarat: Minggu 1 (CRISP-DM & jenis tugas mining)

1. DATA PREPROCESSING

Langkah umum:

- ? Handling missing values ? hapus baris, imputasi mean/median/mode, atau model-based
- ? Outlier ? deteksi (IQR, z-score), cap, atau analisis domain
- ? Encoding ? one-hot untuk kategorikal, scaling untuk numerik
- ? Normalisasi / standardisasi ? penting untuk jarak (mis. K-Means)

Kesalahan preprocessing ? cluster atau model tidak stabil dan sulit diinterpretasi.

2. K-MEANS (INTUISI)

Algoritma unsupervised:

1. Pilih jumlah cluster k
2. Inisialisasi k centroid
3. Assign setiap titik ke centroid terdekat (biasanya jarak Euclidean)
4. Update centroid = rata-rata titik di cluster
5. Ulangi 3?4 hingga konvergen

3. MEMILIH K

- ? Elbow method ? plot inertia vs k, cari ?siku?
- ? Silhouette score ? semakin tinggi, pemisahan cluster semakin jelas (dalam batas tertentu)

4. LATIHAN KONSEPTUAL

Dataset: skor mahasiswa pada 3 fitur numerik (quiz, proyek, partisipasi).
Jelaskan mengapa scaling diperlulu sebelum K-Means.

Kata kunci goal: preprocessing, missing values, K-Means, centroid, silhouette, elbow.